

Análisis de Autocorrelación Espacial de la Productividad Agropecuaria en el Perú

Encuesta Nacional Agropecuaria 2023

Octubre 2025

1. Introducción

Este informe presenta un análisis espacial de la productividad agropecuaria en los distritos del Perú utilizando datos de la ENA 2023. Se implementaron matrices de pesos espaciales, índices de Moran y Geary, análisis LISA y detección de hotspots mediante Getis-Ord G_i^* .

2. Matriz de Pesos Espaciales

Se construyó una matriz de vecindad tipo reina considerando contigüidad de distritos con un umbral de tolerancia de 1×10^{-6} . El análisis identificó 1 distrito sin vecinos y 2 subgrafos en la red espacial, lo cual es esperado dada la geografía insular de algunas zonas del Perú. La matriz fue estandarizada por filas (style="W") para permitir interpretaciones consistentes de los promedios ponderados vecinales, aplicando política de cero vecinos para unidades aisladas.

3. Índice de Moran Global

3.1. Estadísticos

Estadístico	Valor
I de Moran	0.1154
Expectativa	-0.0006
Varianza	0.0002
Z-score	8.1976
p-valor	$< 2,2 \times 10^{-16}$

Cuadro 1: Resultados del test de Moran Global

3.2. Interpretación Estadística

El índice de Moran ($I=0.115$, $p<0.001$) revela autocorrelación espacial positiva significativa en el rendimiento agropecuario distrital. Esto indica que distritos con productividad

similar tienden a agruparse geográficamente, rechazando la hipótesis de distribución aleatoria. El Z-score de 8.20 confirma patrones espaciales robustos en la productividad agrícola peruana.

3.3. Gráfico: Diagrama de Dispersión de Moran




Figura 1: Diagrama de dispersión de Moran mostrando autocorrelación espacial

El scatterplot revela correlación positiva ($I=0.115$) entre el rendimiento distrital y el promedio ponderado de sus vecinos, evidenciando clustering espacial mediante la concentración de observaciones en cuadrantes I (Alto-Alto) y III (Bajo-Bajo). La línea de regresión con pendiente positiva confirma que distritos productivos tienden a estar rodeados de vecinos igualmente productivos, mientras que los puntos dispersos en cuadrantes II y IV representan outliers espaciales. Los ejes centrados en cero permiten identificar visualmente los cuatro tipos de asociación espacial local (HH, LL, HL, LH).

4. Índice de Geary Global

4.1. Estadísticos

Estadístico	Valor
C de Geary	0.8881
Expectativa	1.0000
Varianza	0.0003
Z-score	6.3246
p-valor	$1,27 \times 10^{-10}$

Cuadro 2: Resultados del test de Geary Global

4.2. Interpretación Estadística

El coeficiente de Geary ($C=0.888$, $p<0.001$) complementa el análisis de Moran confirmando autocorrelación positiva, pues $C<1$ indica mayor similitud entre vecinos que en distribución aleatoria. El estadístico $Z=6.32$ valida que las diferencias de rendimiento entre distritos contiguos son sistemáticamente menores que entre distritos distantes, reforzando la presencia de patrones espaciales.

5. Análisis LISA (Moran Local)

5.1. Clasificación de Clústeres

Tipo de Clúster	Color	Interpretación
Alto-Alto	Rojo	Hotspots de alta productividad
Bajo-Bajo	Azul	Coldspots de baja productividad
Alto-Bajo	Naranja	Outliers positivos
Bajo-Alto	Verde	Outliers negativos
No significativo	Gris	Sin patrón espacial

Cuadro 3: Tipología de clústeres LISA

5.2. Interpretación Estadística

El análisis LISA identifica concentraciones locales significativas ($-Z > 1.96$) de productividad agropecuaria. Los clústeres Alto-Alto representan núcleos de excelencia productiva rodeados de vecinos similares, mientras Bajo-Bajo señala zonas deprimidas persistentes. Los outliers espaciales (Alto-Bajo, Bajo-Alto) revelan distritos atípicos respecto a su entorno, sugiriendo factores locales específicos que rompen patrones regionales.

6. Hotspots: Getis-Ord G_i^*

6.1. Clasificación

Categoría	Criterio	Significado
Hotspot	$G_i^* \geq 1.96$	Concentración alta significativa
Coldspot	$G_i^* \leq -1.96$	Concentración baja significativa
No significativo	$-1.96 < G_i^* < 1.96$	Sin clustering

Cuadro 4: Umbrales de significancia para Getis-Ord G_i^*

7. Gráficos de Análisis Espacial

7.1. Gráfico 1: Distribución del Rendimiento Promedio




Figura 2: Histograma de distribución del rendimiento promedio por distrito

El histograma muestra una distribución asimétrica positiva con fuerte concentración en el rango de 1000-3000 kg/ha y una cola derecha extendida hacia valores excepcionales superiores a 10000 kg/ha, revelando heterogeneidad productiva nacional. Esta asimetría refleja la coexistencia de agricultura de subsistencia (pico modal) con sistemas intensivos modernos (outliers derechos), evidenciando brechas tecnológicas y agroclimáticas entre regiones. La exclusión de 360 distritos sin datos señala limitaciones de cobertura muestral en zonas remotas o de difícil acceso geográfico.

7.2. Gráfico 4: Ranking de Zonas Calientes y Frías (Gi*)




Figura 3: Top 20 distritos según estadístico Getis-Ord Gi*

El ranking Gi* identifica los 20 distritos con mayor intensidad de concentración espacial, destacando hotspots (barras rojas positivas) como núcleos de excelencia productiva rodeados de vecindarios igualmente productivos y coldspots (barras azules negativas) como zonas deprimidas persistentes. La magnitud de los Z-scores (± 3 o ± 3 en extremos) indica no solo alta/baja productividad local sino también fuerte homogeneidad vecinal, señalando áreas de intervención prioritaria para políticas públicas diferenciadas. Este método supera a LISA al ponderar la intensidad absoluta del rendimiento, no solo su similitud con vecinos, permitiendo identificar focos de inversión y asistencia técnica.

8. Mapas Temáticos

8.1. Mapa 1: Rendimiento Promedio por Distrito

Productividad Agropecuaria - Distritos del Perú (ENA 2023)




Figura 4: Productividad agropecuaria promedio - Distritos del Perú (ENA 2023)

El mapa coroplético muestra concentraciones de alta productividad (tonos verde oscuro) en valles costeros irrigados, cuencas interandinas con infraestructura hídrica y bolsones de agricultura tecnificada en selva alta, mientras tonos amarillos claros predominan en sierra alta y selva baja marginal. La distribución espacial heterogénea confirma fuerte dependencia de factores agroclimáticos (disponibilidad hídrica, suelos), acceso a mercados urbanos e infraestructura productiva (riego, mecanización). Los vacíos de información (360 distritos sin datos en gris) se concentran en zonas de frontera amazónica y sierra remota, sugiriendo desafíos de cobertura muestral en áreas de difícil acceso.

8.2. Mapa 2: Clústeres LISA (Moran Local)




Figura 5: Análisis LISA - Clústeres de autocorrelación espacial local

Los clústeres Alto-Alto (rojo) identifican corredores productivos consolidados principalmente en costa norte (Lambayeque, La Libertad), valles interandinos del centro (Junín, Huánuco) y selva alta (San Martín), donde la productividad elevada es compartida espacialmente por vecinos formando núcleos de competitividad. Las zonas Bajo-Bajo (azul) marcan bolsones de pobreza productiva persistente en sierra sur (Puno, Apurímac) y selva baja (Loreto, Ucayali), sugiriendo trampas espaciales de bajo rendimiento que requieren intervenciones estructurales. Los outliers espaciales Alto-Bajo (naranja) y Bajo-Alto (verde) señalan distritos atípicos cuyo desempeño contrasta con su entorno, indicando factores locales específicos (proyectos exitosos, microclimas favorables) que merecen investigación para replicación.

8.3. Mapa 3: Hotspots y Coldspots (Getis-Ord Gi*)

Zonas Calientes y Frías de Productividad - ENA 2023




Figura 6: Zonas calientes y frías de productividad agropecuaria

Los hotspots (rojo) delimitan núcleos de excelencia productiva con efectos de derrame positivo hacia vecinos, concentrados en valles costeros de Ica, Lima y Arequipa (agroexportación intensiva), así como cuencas tecnificadas de Junín y Cajamarca. Los coldspots (azul) revelan trampas espaciales de baja productividad persistente en sierra sur (altiplano puneño) y selva amazónica, donde limitaciones estructurales (acceso, tecnología, suelos) generan círculos viciosos de subdesarrollo agrícola regional. Las zonas grises no significativas (mayoría del territorio) indican ausencia de clustering espacial extremo, representando heterogeneidad local donde intervenciones deben ser diferenciadas según contextos distritales específicos.

9. Conclusiones

1. La productividad agropecuaria en Perú presenta autocorrelación espacial positiva robusta (Moran I=0.115, Geary C=0.888, ambos $p < 0.001$), evidenciando clustering geográfico significativo de distritos similares y rechazando hipótesis de distribución aleatoria espacial.
2. Los análisis LISA y Hotspots complementarios identifican núcleos específicos de alta

(hotspots en costa y valles) y baja (coldspots en sierra sur y selva) productividad, útiles para focalización territorial de políticas públicas, transferencia tecnológica y asignación eficiente de recursos.

3. La heterogeneidad regional (Costa más dispersa que Sierra/Selva) y presencia de outliers espaciales sugieren que factores locales (riego, tecnología, mercados, capital humano) modulan significativamente los patrones macroespaciales determinados por clima y geografía física.
4. La coincidencia metodológica baja (5.34 %) entre LISA y G_i^* refleja complementariedad conceptual: el primero detecta asociación espacial relativa útil para entender difusión, el segundo identifica concentración absoluta crítica para priorización de inversiones públicas.