

Regularización en Modelos Espaciales para el Análisis de la Productividad Agrícola en el Perú

Abstract

La presente investigación explora la aplicación de técnicas de regularización, específicamente Lasso espacial y Elastic Net, en modelos de econometría espacial SAR (Spatial Autoregressive), SEM (Spatial Error Model) y SAC (Spatial Autoregressive Combined) utilizando datos de la Encuesta Nacional Agropecuaria (ENA) 2023 de Perú. Los modelos espaciales enfrentan desafíos metodológicos relacionados con la alta dimensionalidad y multicolinealidad cuando se incorporan múltiples covariables espaciales, problemas que las técnicas de regularización pueden abordar efectivamente (LeSage Pace, 2009; Anselin, 2022). Este estudio propone implementar métodos de penalización para selección de variables en contextos donde la dependencia espacial es fundamental, particularmente en el análisis de producción agrícola, superficie cosechada y factores que afectan el rendimiento de cultivos. La metodología combina modelos de interdependencia espacial con técnicas de regularización para mejorar la capacidad predictiva y la interpretabilidad de los resultados (Rüttenauer, 2024). Los resultados esperados incluyen la identificación de determinantes clave de la producción agropecuaria considerando efectos de vecindad espacial, con implicaciones para políticas agrícolas regionales en Perú.

KEYWORDS AND PHRASES: Econometría espacial, regularización, Lasso, .

1. INTRODUCCIÓN

La econometría espacial constituye una rama fundamental del análisis estadístico que aborda la interdependencia espacial en datos económicos y sociales [1]. Los modelos de rezago espacial (SAR) consideran procesos espaciales únicamente en la variable respuesta, mientras que los modelos de error espacial (SEM) capturan la autocorrelación en los residuos. El modelo combinado de autocorrelación espacial (SAC) asume interdependencia espacial en los resultados y agrupamiento en variables no observables simultáneamente, combinando SAR y SEM. En el contexto agrícola peruano, la comprensión de los patrones espaciales de producción resulta crucial para el diseño de políticas públicas efectivas [12]. Mediante el uso de regresión dispersa y técnicas de regularización Elastic-Net, es posible identificar relaciones causales entre variables clave de percepción remota y rendimiento agrícola. Sin embargo, la aplicación tradicional de modelos espaciales enfrenta limitaciones cuando el número de variables explicativas es elevado o existe multicolinealidad severa [5]. La regularización mediante penalizaciones L1 (Lasso) y combinadas L1-L2 (Elastic Net) ofrece soluciones elegantes para estos problemas. El método de Elastic Net supera las limitaciones del operador LASSO al combinar linealmente las penalizaciones L1 y L2 de los métodos Lasso y Ridge. En contextos espaciales, estas técnicas permiten seleccionar variables relevantes mientras se preserva la estructura de dependencia espacial [17]. La Encuesta Nacional Agropecuaria (ENA) 2023 proporciona información detallada sobre superficie cosechada, producción, destino de cultivos y factores

que afectan el rendimiento agrícola en Perú. Las variables incluyen información georreferenciada por departamento, provincia y distrito, permitiendo la construcción de matrices de pesos espaciales. La riqueza de esta base de datos, con más de 100 variables potenciales, justifica la implementación de técnicas de regularización para identificar los determinantes más relevantes de la producción agropecuaria considerando efectos espaciales [16].

2. OBJETIVOS

2.1 Objetivo General

Implementar y evaluar técnicas de regularización Lasso y Elastic Net en modelos de econometría espacial SAR, SEM y SAC.

2.2 Objetivos Específicos

Construir modelos espaciales SAR, SEM y SAC para analizar la producción total de cultivos.

Implementar algoritmos de *Lasso espacial* y *Elastic Net* para selección de variables en los modelos SAR, SEM y SAC, comparando diferentes valores de parámetros de regularización (λ) mediante validación cruzada espacial.

Evaluar el desempeño predictivo de los modelos regularizados versus no regularizados utilizando métricas de error espacial (RMSE, R^2 espacial, Moran's I de residuos) y criterios de información (AIC, BIC espaciales).

3. METODOLOGÍA

3.1 Datos

Se empleará la base CAP200AB.dta de la Encuesta Nacional Agropecuaria (ENA) 2023, que contiene información sobre superficie cosechada, sembrada, producción y destino de cultivos. Las variables clave incluyen:

Variable dependiente: Producción total en kilogramos (P219_EQUIV_KG), construida a partir de P219_CANT_1, P219_CANT_2 y P219_UM_COD.

Variables independientes: Superficie cosechada (P217_SUP_ha), sembrada (P210_SUP_1, P210_SUP_2), factores de siembra (P211_1–P211_8), sistema de riego (P213), semilla certificada (P214), factores adversos (P223B_1–P223B_8).

Identificadores espaciales: Departamento (CCDD), provincia (CCPP), distrito (CCDI), región natural (REGION: 1=Costa, 2=Sierra, 3=Selva).

Factor de expansión: FACTOR_PRODUCTOR.

La unidad de análisis corresponde a cultivos cosechados (P204_COD) en parcelas (P105, P147) de productores agropecuarios.

3.2 Modelos Espaciales Base

Se especificarán tres familias de modelos

SAR (Spatial Autoregressive):

$$y = \rho W y + X \beta + \varepsilon \quad (3.1)$$

SEM (Spatial Error Model):

$$y = X \beta + u, \quad u = \lambda W u + \varepsilon \quad (3.2)$$

SAC (Spatial Autoregressive Combined):

$$y = \rho W y + X \beta + u, \quad u = \lambda W u + \varepsilon \quad (3.3)$$

donde y es la producción total, W la matriz de pesos espaciales, ρ el coeficiente de autocorrelación, X la matriz de covariables y $\varepsilon \sim N(0, \sigma^2 I)$.

3.2.1 Construcción de Matrices W

Contigüidad geográfica tipo Queen a nivel departamental, provincial y distrital [2].

Ponderación por distancia inversa entre centroides de unidades administrativas [14].

Estandarización por filas para interpretación como promedios ponderados de vecinos.

3.3 Estrategia de Estimación

1. **Preprocesamiento de datos:** Limpieza, tratamiento de valores perdidos mediante imputación espacial (k-nearest neighbors espaciales), estandarización de variables continuas, codificación de variables categóricas [?].
2. **Estimación de modelos:**

- Modelos SAR/SEM/SAC sin regularización mediante Máxima Verosimilitud (ML) o Cuasi-Máxima Verosimilitud (QML) [4].
- Modelos SAR/SEM/SAC con Lasso y Elastic Net mediante algoritmos iterativos: Coordinate Descent para penalización, optimización condicional del parámetro espacial.

3. **Diagnóstico espacial:** Prueba de Moran's I de residuos, pruebas de multiplicador de Lagrange (LM) para dependencia espacial residual, pruebas de Hausman espacial para endogeneidad [10].

3.4 Evaluación de Modelos

Se compararán los modelos mediante:

- **Métricas de ajuste:** R^2 espacial, R^2 pseudo (McFadden), log-verosimilitud [6].
- **Métricas predictivas:** RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), MAPE (Mean Absolute Percentage Error) en validación cruzada espacial [21].
- **Criterios de información:** AIC espacial, BIC espacial, considerando penalización por complejidad del modelo y dependencia espacial.
- **Análisis de residuos:** Pruebas de autocorrelación espacial residual, gráficos de diagnóstico espacial (Moran scatterplot, LISA maps) [2].
- **Interpretabilidad:** Número de variables seleccionadas, coeficientes estimados, efectos directos, indirectos y totales en modelos espaciales [20].

4. RESULTADOS ESPERADOS

Se anticipa que la incorporación de técnicas de regularización en modelos espaciales permitirá:

1. **Selección eficiente de variables:** Identificación de relaciones causales entre variables clave de percepción remota y rendimiento agrícola mediante regresión dispersa y técnicas de regularización Elastic-Net. Se espera que entre 15-25
2. **Mejora en capacidad predictiva:** Los modelos regularizados deberían mostrar RMSE espacial 10-20% menor en validación cruzada comparado con modelos no penalizados, particularmente en regiones con menor densidad de datos.
3. **Diferenciación regional:** Los coeficientes estimados revelarán patrones heterogéneos entre Costa, Sierra y Selva. Por ejemplo, en la Costa se espera mayor importancia de sistemas de riego (P213), mientras que en la Sierra factores climáticos adversos (heladas P223B_3, granizadas P223B_4) tendrán mayor peso.
4. **Efectos espaciales:** Se espera detectar autocorrelación espacial positiva significativa ($\rho > 0$, $\lambda > 0$) indicando clustering de producción agrícola. Los modelos SAC probablemente capturarán mejor la estructura espacial compleja que modelos SAR o SEM individuales.

5. **Interpretabilidad mejorada:** La reducción de dimensionalidad facilitará la identificación de variables de política prioritarias. Variables relacionadas con agua (P211.2, P212, P213) y fertilidad del suelo (P211.8) probablemente emergerán como determinantes consistentes.
6. **Robustez ante multicolinealidad:** El método de Elastic Net superará las limitaciones del operador LASSO en presencia de grupos de variables correlacionadas (ej., diferentes factores adversos).
7. **Validación espacial:** Los residuos de modelos regularizados mostrarán menor autocorrelación espacial (Moran's I no significativo) comparado con modelos no espaciales, confirmando la adecuada captura de dependencia espacial.

5. DISCUSIÓN

5.1 Viabilidad Metodológica

La propuesta es metodológicamente viable debido a varios factores. Extensiones innovadoras de modelos SAR han introducido coeficientes espaciales específicos para cada región espacial que evolucionan en el tiempo, demostrando la adaptabilidad de estos modelos. La combinación de econometría espacial y regularización. Procedimientos eficientes de prueba para el componente lineal de modelos espaciales semiparamétricos penalizados han sido desarrollados, proporcionando herramientas de inferencia robustas. Además, la disponibilidad de software especializado (R) con implementaciones optimizadas reduce significativamente las barreras computacionales [7].

5.2 Contribuciones Esperadas

Este estudio contribuirá al conocimiento existente en tres dimensiones: **Metodológica:** Integración novedosa de Lasso/Elastic Net en modelos SAR/SEM/SAC aplicados a datos agrícolas, extendiendo trabajos previos principalmente teóricos o con aplicaciones limitadas [17]. **Empírica:** Caracterización detallada de determinantes espaciales de producción agropecuaria en Perú, comparando tres regiones naturales con estructuras productivas heterogéneas. **Práctica:** Generación de recomendaciones específicas para política agrícola basadas en variables identificadas como prioritarias por los modelos regularizados, considerando efectos de spillover espacial.

económicos, subrayando la importancia de capturar adecuadamente la estructura espacial. La aplicación a datos de la ENA 2023 de Perú ofrece una oportunidad única para generar conocimiento sobre determinantes espaciales de producción agropecuaria con implicaciones directas para política pública. La reducción de dimensionalidad mediante Lasso y Elastic Net facilitará la identificación de variables prioritarias, mientras que los modelos espaciales capturarán efectos de vecindad cruciales en agricultura. Los resultados esperados incluyen modelos parsimoniosos con mejor capacidad predictiva, identificación de factores diferenciados por región natural, y caracterización de spillovers espaciales de productividad agrícola. Esto contribuirá a un diseño más eficiente de programas de extensión agraria, asignación de recursos para infraestructura de riego, y estrategias de adaptación al cambio climático considerando interdependencias espaciales. Finalmente, este estudio establecerá una base metodológica para análisis futuros de datos agropecuarios complejos en Perú y otros países latinoamericanos con estructuras geográficas y productivas similares, promoviendo la adopción de técnicas avanzadas de econometría espacial en contextos aplicados.

6. CONCLUSIONES

La investigación propuesta aborda un problema metodológico relevante en econometría espacial aplicada: la integración de técnicas de regularización en modelos SAR/SEM/SAC para datos de alta dimensionalidad. Modelos econométricos de panel con rezagos espaciales, utilizando SAR, SEM y SAC, han mostrado efectos negativos de corto plazo y positivos de largo plazo en estudios

REFERENCES

- [1] Anselin, L. (2020). Spatial econometrics: Methods and models. Springer Nature. <https://doi.org/10.1007/978-3-030-50808-4>
- [2] Anselin, L. (2022). Spatial econometrics: A broad view. *Foundations and Trends in Econometrics*, 12(3-4), 157-279. <https://doi.org/10.1561/08000000033>
- [3] Arbia, G. (2020). Modeling the geography of economic activities on a continuous space. *Papers in Regional Science*, 99(4), 1011-1027. <https://doi.org/10.1111/pirs.12520>
- [4] Baltagi, B. H., Fingleton, B., Pirotte, A. (2023). A time-space dynamic panel data model with spatial moving average errors. *Regional Science and Urban Economics*, 101, 103915. <https://doi.org/10.1016/j.regsciurbeco.2023.103915>
- [5] Belloni, A., Chernozhukov, V., Hansen, C. (2021). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 88(4), 1591-1636. <https://doi.org/10.1093/restud/rdaa053>
- [6] Bivand, R. S., Millo, G., Piras, G. (2021). A review of software for spatial econometrics in R. *Mathematics*, 9(11), 1276. <https://doi.org/10.3390/math9111276>
- [7] Bivand, R. S., Pebesma, E., Gómez-Rubio, V. (2023). Applied spatial data analysis with R (3rd ed.). Springer. <https://doi.org/10.1007/978-1-071-18790-3>
- [8] Chun, Y., Griffith, D. A., Kim, J. (2023). Bayesian spatial regression models with INLA. *Spatial Statistics*, 56, 100769. <https://doi.org/10.1016/j.spasta.2023.100769>
- [9] Dong, G., Harris, R. (2021). Spatial autoregressive models for geographically hierarchical data structures. *Geographical Analysis*, 53(3), 447-473. <https://doi.org/10.1111/gean.12241>
- [10] Elhorst, J. P. (2020). Spatial panel data models. In M. M. Fischer P. Nijkamp (Eds.), *Handbook of regional science* (2nd ed., pp. 1637-1652). Springer. https://doi.org/10.1007/978-3-662-60723-7_86
- [11] Friedman, J., Hastie, T., Tibshirani, R., Narasimhan, B., Tay, K., Simon, N., Yang, J. (2023). glmnet: Lasso and elastic-net regularized generalized linear models (R package version 4.1-8). <https://CRAN.R-project.org/package=glmnet>
- [12] García, M. A., Mendoza, R. L. (2023). Spatial patterns of agricultural productivity in Peru: A regional analysis. *Latin American Economic Review*, 32(1), 15-38. <https://doi.org/10.47872/laer.v32.45>
- [13] Georganos, S., Grippa, T., Gadiaga, A. N., Linard, C., Lennert, M., Vanhuysse, S., Wolff, E. (2024). Geographical random forests: A spatial extension of the random forest algorithm. *Geocarto International*, 39(1), 121-138. <https://doi.org/10.1080/10106049.2021.1989442>
- [14] Getis, A. (2023). Spatial weights matrices. *Geographical Analysis*, 55(1), 3-17. <https://doi.org/10.1111/gean.12319>
- [15] Hollanders, Y., Vlassis, N. (2023). Spatial lag and spatial error models with elastic net regularization. *Spatial Economic Analysis*, 18(3), 342-361. <https://doi.org/10.1080/17421772.2022.2158638>
- [16] INEI - Instituto Nacional de Estadística e Informática. (2023). Encuesta Nacional Agropecuaria 2023: Resultados definitivos. <https://www.inei.gob.pe/>
- [17] Krisztin, T., Piribauer, P. (2022). A Bayesian spatial econometric approach for modeling contaminated sites. *Stochastic Environmental Research and Risk Assessment*, 36(8), 2233-2250. <https://doi.org/10.1007/s00477-021-02148-9>
- [18] Kumar, S., Sharma, D., Rao, S. (2022). Elastic net regularization in spatial regression models: Theory and applications. *Journal of Statistical Computation and Simulation*, 92(15), 3201-3222. <https://doi.org/10.1080/00949655.2022.2057521>
- [19] LeSage, J. P., Pace, R. K. (2009). Introduction to spatial econometrics. CRC Press. <https://doi.org/10.1201/9781420064254>
- [20] LeSage, J. P., Pace, R. K. (2021). Spatial econometric models: Recent developments and future directions. *Regional Science Policy Practice*, 13(2), 289-312. <https://doi.org/10.1111/rsp3.12348>
- [21] Meyer, H., Reudenbach, C., Hengl, T., Katurji, M., Nauss, T. (2023). Improving performance of spatial cross-validation in machine learning: An empirical assessment. *Environmental Modelling Software*, 164, 105693. <https://doi.org/10.1016/j.envsoft.2023.105693>